

O corpus do projeto: *Cidades baixada Santista*

GGYes

29 de setembro de 2026

Fatec Baixada Santista – Rubens Lara

Tecnologia em Ciência de Dados | Projeto Integrador III — Motor de Busca | Prof. Dr.
João Paulo Ferreira de Mello

Gabrielle Lara Moricz de Souza – RA 0051352511001

Giulia Dias Granado de Marques – RA 0051352511003

Yuri Salgado Pinto – RA 0051352511034

Repositório: Motorbusa-R

1 Introdução

O tema do motor se encontra em informações gerais quanto as cidades de Santos, São Vicente e Cubatão, atendendo as necessidades de conhecimentos históricos, estruturais e de dados quantitativos como população. Assim, o motor serve para pessoas interessadas nas cidades de uma maneira mais didática ou, a certo nível, buscando se informar por propósitos de visitaç o ou mudan a. Para atender essas necessidades, foram usadas de fonte as p ginas da wikip dia das cidades antes mencionadas.

2 A fonte e o documento

O corpus foi criado apartir de tr s documentos da *Wikipedia foundation*: Santos, Cubat o e S o Vicente (S o Paulo) todos com a licen a ‘*Creative Commons Atribui o-CompartilhaIgual (CC BY-SA)*’ e acessados no dia 15 de Setembro (2026). Tal corpus conta com 166 documento vindos das tr s p ginas, cada uma sendo um par grafo. Isso foi feito para que se possam fazer perguntas espec ficas para buscar informa  es dentro dos textos, e n o apenas perguntas retornando a cidade mais apropriada como seria o caso se cada documento fosse uma p gina inteira.

3 Como o corpus foi obtido

Foram importados das páginas da wikipedia todos os parágrafos com mais de 30 caracteres. Estes documentos foram identificados com um id, a identificação de a qual corpo pertencem e sua posição relativa aos documentos pertencentes apenas a este corpo.

4 Defesa do corpus

A Tabela 1 reúne as verificações feitas sobre o corpus como um todo, enquanto a Tabela 2 foca em cada página utilizada

Tabela 1 – Diagnóstico do corpus

Verificação	Resultado
Tamanho páginas	166 documentos de 3
Tokens por documento	3 a 241 (média 80.4759)
Vocabulário bruto	4993 termos distintos em 13359 tokens
Página que domina	Corpus de Santos: 95 de 166 (57,2%)
Documentos suspeitos	19 com menos de 20 tokens 0 com mais de 300
Sujeira	1317 com acento, 76 com pontuação, 542 com dígitos

Fonte: Elaborada pelos autores a partir de docs.rds e origem.rds.

Tabela 2 – Documentos por página de origem

Página	Documentos	Tokens (média)
Santos	95	91
São vicente	33	64
Cubatão	38	68

Fonte: Elaborada pelos autores.

Tamanho. O valor está acima da faixa de meta (20-30), isso por que foi decidido que usar as páginas de mais de uma cidade seria melhor para o projeto e as páginas em si continham muitos documentos.


Domínio de uma página. Como evidenciado na tabela 2, o número de documentos vindos de Santos é significativamente maior que os demais, o que é coerente com o fato de ser a maior cidade da baixada Santista. Decide-se manter a cidade mesmo com a desproporcionalidade pela sua importância. Uma possível medida de remediação seria adicionar as restantes cidades da baixada ao corpus

Documentos que não são prosa. Os documentos muito curtos da Tabela 1 são principalmente títulos de seções e legendas. Possivelmente deve-se realizar um acoplamento destes com suas respectivas seções, principalmente para listas.

Sujeira. Foi contada por token ao invés de por documento, representa menos de 1/6 do total de tokens.

A Figura 1 mostra a distribuição dos tamanhos.

Figura 1 – Tokens por documento



Fonte: Elaborada pelos autores.

Os termos mais frequentes são de, a, e, o, do, da, em, que, Santos e cidade. A maior parte são gramemas, o que é de se esperar para quase qualquer corpus, os outros dois são coerentes com o tema de escolha. Observa-se que ‘Santos’ aparece em todas as páginas da wikipédia de cidades da baixada santista, tanto as incluídas no corpus quanto as não incluídas

Veredito. Como panorama geral, o corpus responde perguntas básicas em relação as cidades, mas é principalmente útil se a informação buscada é sobre Santos em particular, por representar a maior parte dos documentos. Ainda há possibilidades de melhoria do corpus, apesar de ter performance menos ideal para turismo, ele atende a necessidade didática.

Referências

Wikimedia Foundation. *Wikipédia, a enciclopédia livre*. 2026. <<https://pt.wikipedia.org>>. Conteúdo sob licença CC BY-SA 4.0. Acesso em: <dia mês ano>.