

# O corpus do projeto: *Cidades baixada Santista*

GGYes

2 de outubro de 2026

Fatec Baixada Santista – Rubens Lara

Tecnologia em Ciência de Dados | Projeto Integrador III — Motor de Busca | Prof. Dr.  
João Paulo Ferreira de Mello

Gabrielle Lara Moricz de Souza – RA 0051352511001

Giulia Dias Granado de Marques – RA 0051352511003

Yuri Salgado Pinto – RA 0051352511034

Repositório: *MotordeBusca<sub>R</sub>*

## 1 Introdução

O tema do motor se encontra em informações gerais quanto as cidades de Santos, São Vicente e Cubatão, atendendo as necessidades de conhecimentos históricos, estruturais e de dados quantitativos como população. Assim, o motor serve para pessoas interessadas nas cidades de uma maneira mais didática ou, a certo nível, buscando se informar por propósitos de visitação ou mudança. Para atender essas necessidades, foram usadas de fonte as páginas da wikipédia das cidades antes mencionadas.

## 2 A fonte e o documento

O corpus foi criado apartir de três documentos da Wikipedia foundation: Santos, Cubatão e São Vicente (São Paulo) todos com a licença ‘Creative Commons Atribuição-CompartilhaIgual (CC BY-SA)’ e acessados no dia 15 de Setembro (2026). Tal corpus conta com 166 documento vindos das três páginas, cada uma sendo um parágrafo. Isso foi feito para que se possam fazer perguntas específicas para buscar informações dentro dos textos, e não apenas perguntas retornando a cidade mais apropriada como seria o caso se cada documento fosse uma página inteira.

### 3 Como o corpus foi obtido

Foram importados das páginas da wikipedia todos os parágrafos com mais de 30 caracteres. Estes documentos foram identificados com um id, a identificação de a qual corpo pertencem e sua posição relativa aos documentos pertencentes apenas a este corpo.

### 4 Defesa do corpus

A Tabela 1 reúne as verificações feitas sobre o corpus, e a Tabela 2 mostra de onde veio cada documento.

Tabela 1 – Diagnóstico do corpus

| Verificação                        | Resultado                                                   |
|------------------------------------|-------------------------------------------------------------|
| Tamanho ( $N$ documentos, páginas) | 166 documentos de 3 páginas                                 |
| Tokens por documento               | 3 a 239 (média 80,4)                                        |
| Vocabulário bruto                  | 4462 termos distintos em 13354 tokens                       |
| Página que domina                  | <b>Santos:</b> 95 de 166 (57%)                              |
| Documentos suspeitos               | 19 com menos de 20 tokens; 0 com mais de 300                |
| Sujeira                            | 162 com acento, 160 com pontuação, 120 com dígitos (de 166) |

Fonte: Elaborada pelos autores a partir de `docs.rds` e `origem.rds`.

Tabela 2 – Documentos por página de origem

| Página                  | Documentos | Tokens (média) |
|-------------------------|------------|----------------|
| Santos                  | 95         | 91,3           |
| Cubatão                 | 38         | 68,8           |
| São Vicente (São Paulo) | 33         | 62,7           |

Fonte: Elaborada pelos autores.

**Tamanho.** O valor está acima da faixa de meta (20-30), isso por que foi decidido que usar as páginas de mais de uma cidade seria melhor para o projeto e as páginas em si continham muitos documentos.


**Domínio de uma página.** Como evidenciado na tabela 2, o número de documentos vindos de Santos é significantemente maior que os demais, o que é coerente com o fato de ser a maior cidade da baixada Santista. Decide-se manter a cidade mesmo com a desproporcionalidade pela sua importância. Uma possível medida de remediação seria adicionar as restantes cidades da baixada ao corpus

**Documentos que não são prosa.** Os documentos muito curtos da Tabela 1 são principalmente títulos de seções e legendas. Possivelmente deve-se realizar um acoplamento destes com suas respectivas seções, principalmente para listas.

**Sujeira.** Foi contada por token ao invés de por documento, representa menos de 1/6 do total de tokens.

A Figura 1 mostra a distribuição dos tamanhos.

Figura 1 – Tokens por documento



Fonte: Elaborada pelos autores.

**Os termos mais frequentes** são de, a, e, o, do, da, em, que, Santos e cidade. A maior parte são gramemas, o que é de se esperar para quase qualquer corpus, os outros dois são coerentes com o tema de escolha. Observa-se que ‘Santos’ aparece em todas as páginas da wikipédia de cidades da baixada santista, tanto as incluídas no corpus quanto as não incluídas

**Veredito.** Como panorama geral, o corpus responde perguntas básicas em relação as cidades, mas é principalmente útil se a informação buscada é sobre Santos em particular, por representar a maior parte dos documentos. Ainda há possibilidades de melhoria do corpus, apesar de ter performance menos ideal para turismo, ele atende a necessidade didática.